RINGKASAN

Proyek ini menerapkan algoritma Decision Tree untuk mengklasifikasikan Burnout_Risk_Level pada dataset “AI Impact on Students” dari Kaggle. Dataset yang dijalankan pada Google Colab terdiri atas 50.000 observasi dan 16 kolom. Target mencakup tiga kelas: Low (16.369), Medium (21.144), dan High (12.487). Pemeriksaan awal menunjukkan tidak ada nilai kosong maupun baris duplikat persis. Model menggunakan 11 fitur terpilih dan pemisahan data latih-uji 80:20 secara stratified.

Decision Tree dioptimasi melalui GridSearchCV dengan StratifiedKFold tiga lipatan. Kombinasi terbaik menggunakan criterion=entropy, max_depth=8, dan min_samples_leaf=50 dengan F1-macro validasi silang 0,5262. Pada 10.000 observasi data uji, model menghasilkan accuracy 51,72%, balanced accuracy 50,63%, dan F1-macro 0,5183; ketiganya lebih tinggi dibanding baseline kelas mayoritas. Akan tetapi, recall kelas High sekitar 44%, sehingga model belum dapat diperlakukan sebagai instrumen penilaian risiko burnout yang andal bagi mahasiswa secara individual.

Kata kunci: klasifikasi multikelas; Decision Tree; burnout; mahasiswa; GenAI; data mining.

BAB I. PENDAHULUAN

1.1 Latar Belakang

Penggunaan Generative Artificial Intelligence (GenAI) semakin terintegrasi dalam kegiatan belajar, mulai dari merangkum bacaan, menyusun tulisan, hingga membantu pemrograman. Data penggunaan AI dan kebiasaan belajar dapat dieksplorasi sebagai konteks analisis risiko burnout mahasiswa. Klasifikasi multikelas memungkinkan setiap observasi ditempatkan pada kategori risiko Low, Medium, atau High berdasarkan karakteristik yang tersedia dalam dataset.

Decision Tree merupakan algoritma supervised learning yang membangun aturan pemisahan data berbentuk pohon keputusan. Selain menghasilkan prediksi, struktur percabangannya dapat ditinjau untuk memahami fitur yang digunakan model. Meski demikian, hubungan yang ditemukan model adalah pola prediktif dalam dataset, bukan bukti bahwa penggunaan AI menyebabkan burnout.

1.2 Rumusan Masalah

- Bagaimana distribusi tingkat risiko burnout pada dataset AI Impact on Students?
- Bagaimana penerapan preprocessing dan Decision Tree untuk klasifikasi tiga tingkat risiko burnout?
- Bagaimana kinerja Decision Tree setelah tuning hyperparameter dibandingkan baseline kelas mayoritas?
- Fitur apa yang paling dominan dalam keputusan model dan apa keterbatasan interpretasinya?

1.3 Tujuan

- Mengidentifikasi karakteristik dataset dan distribusi kelas target.
- Membangun pipeline klasifikasi Decision Tree menggunakan Python dan scikit-learn.
- Menilai model dengan accuracy, balanced accuracy, precision, recall, F1-macro, dan confusion matrix.
- Menganalisis feature importance serta keterbatasan pengaplikasian hasil model.

1.4 Batasan

Analisis menggunakan dataset publik Kaggle dan belum diverifikasi sebagai sampel representatif kondisi mahasiswa yang sebenarnya. Proyek dibatasi pada klasifikasi berdasarkan 11 atribut yang tersedia dalam notebook, tanpa pengujian lapangan, pemeriksaan kualitas label oleh ahli, atau validasi eksternal. Temuan deskriptif dan feature importance tidak diperlakukan sebagai hubungan sebab-akibat.

BAB II. DATA DAN METODE

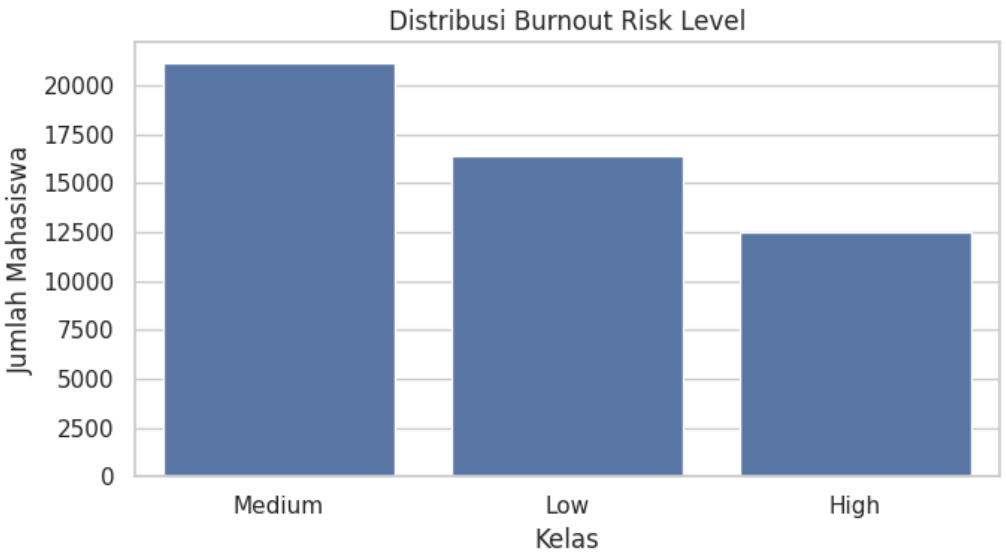
2.1 Sumber Data dan Karakteristik

Dataset diakses dengan kagglehub pada Google Colab menggunakan identitas laveshjadon/ai-impact-on-students dan berkas ai_student_impact_dataset.csv. Hasil pemuatan adalah 50.000 baris dan 16 kolom. Pemeriksaan menghasilkan 0 duplikat persis dan 0 missing value untuk semua kolom. Student_ID berfungsi sebagai identifikasi dan tidak digunakan sebagai prediktor.

Komponen	Deskripsi
Target	Burnout_Risk_Level: Low, Medium, High.
Fitur numerik (5)	Pre_Semester_GPA; Weekly_GenAI_Hours; Tool_Diversity; Traditional_Study_Hours; Perceived_AI_Dependency.
Fitur kategorikal (6)	Major_Category; Year_of_Study; Primary_Use_Case; Prompt_Engineering_Skill; Paid_Subscription; Institutional_Policy.
Kolom tidak dimodelkan	Student_ID; Anxiety_Level_During_Exams; Post_Semester_GPA; Skill_Retention_Score.

2.2 Distribusi Kelas

Kelas	Jumlah	Persentase
Low	16.369	32,74%
Medium	21.144	42,29%
High	12.487	24,97%

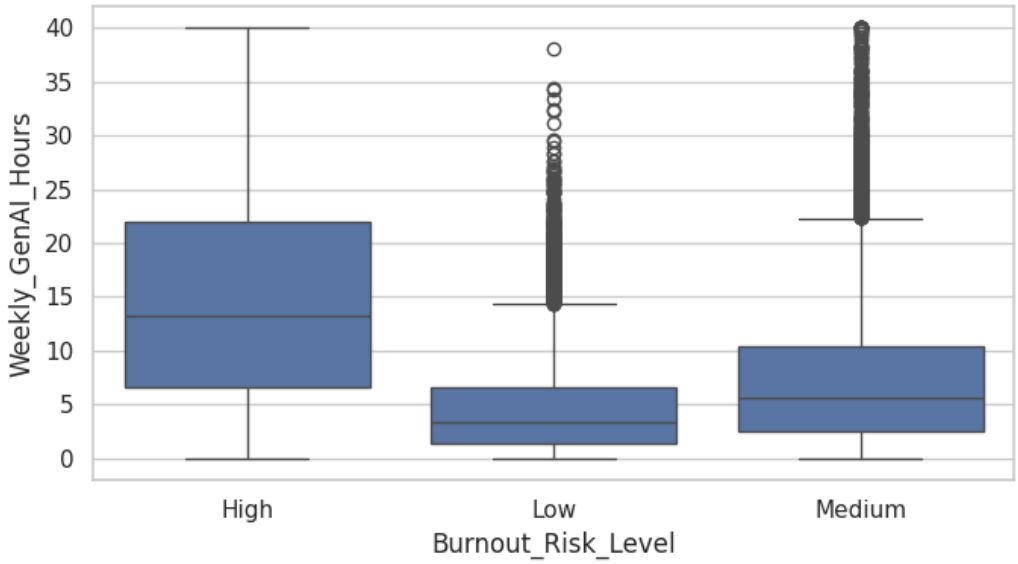


Gambar 1. Distribusi tingkat risiko burnout (grafik asli dari Google Colab).

Kelas Medium merupakan kelompok terbesar (42,29%), sedangkan High merupakan kelompok paling sedikit (24,97%). Ketidakseimbangan kelas menjadi alasan untuk menilai F1-macro dan balanced accuracy, bukan hanya akurasi total.

2.3 Exploratory Data Analysis

EDA dilakukan menggunakan histogram untuk Weekly_GenAI_Hours, Traditional_Study_Hours, Perceived_AI_Dependency, dan Pre_Semester_GPA. Notebook juga menghasilkan boxplot penggunaan GenAI per kelas burnout.



Gambar 2. Distribusi jam penggunaan GenAI mingguan menurut kelas risiko burnout.

Berdasarkan boxplot, kelas High memiliki median waktu penggunaan GenAI mingguan lebih tinggi daripada kelompok Low maupun Medium. Temuan ini memperlihatkan perbedaan distribusi di dalam dataset, tetapi tidak membuktikan bahwa lamanya penggunaan GenAI merupakan penyebab burnout.

2.4 Pembagian Data dan Preprocessing

Sebanyak 40.000 baris dialokasikan sebagai data latih dan 10.000 sebagai data uji dengan train_test_split(test_size=0.2, stratify=y, random_state=42). Sebanyak lima fitur numerik diproses melalui SimpleImputer(strategy="median"), sedangkan enam fitur kategorikal memakai SimpleImputer(strategy="most_frequent") dan OneHotEncoder(handle_unknown="ignore", sparse_output=False). Seluruh transformasi ditempatkan dalam Pipeline sebelum DecisionTreeClassifier sehingga fitting preprocessing dilakukan di setiap fold pada data latih. StandardScaler tidak digunakan karena pohon keputusan berbasis aturan pemisahan nilai.

2.5 Decision Tree dan Tuning Hyperparameter

Decision Tree menentukan pemisahan atribut pada node untuk membentuk kelompok yang semakin homogen menurut target kelas. Pemodelan dalam notebook menguji kriteria gini dan entropy, kedalaman maksimum 3/5/8/12, dan min_samples_leaf 5/20/50. GridSearchCV mengevaluasi 24 kombinasi parameter memakai StratifiedKFold tiga lipatan, dengan scoring F1-macro.

Hyperparameter terpilih	Nilai

Hyperparameter terpilih	Nilai
criterion	entropy
max_depth	8
min_samples_leaf	50
F1-macro cross-validation	0,5262

Untuk pembanding, DummyClassifier(strategy="most_frequent") digunakan sebagai baseline yang selalu memilih kelas target paling sering muncul. Baseline tersebut penting untuk memastikan model tidak hanya mengandalkan dominasi kelas Medium.

BAB III. HASIL DAN PEMBAHASAN

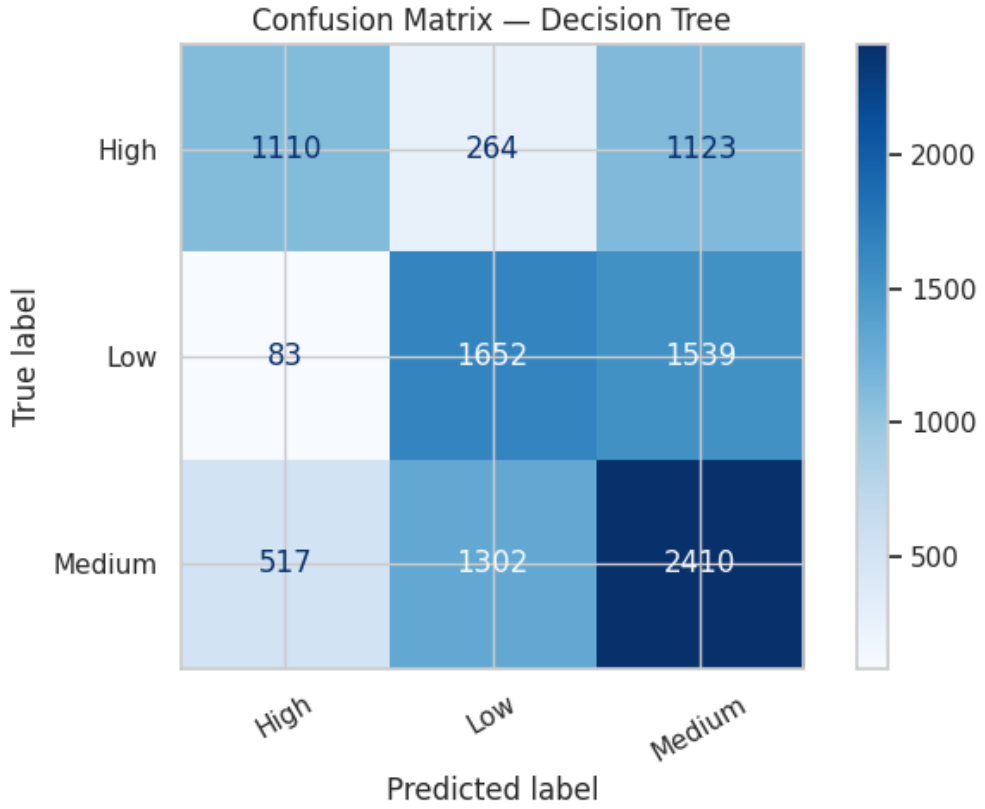
3.1 Perbandingan Kinerja pada Data Uji

Model	Accuracy	Balanced Acc.	F1-macro
Baseline	42,29%	33,33%	0,1981
Decision Tree	51,72%	50,63%	0,5183

Decision Tree meningkatkan akurasi sebesar 9,43 poin persentase dibanding baseline. Kenaikan F1-macro dari 0,1981 menjadi 0,5183 memperlihatkan kemampuan klasifikasi antarkelas yang lebih baik daripada strategi menebak kelas terbanyak. Walaupun demikian, accuracy 51,72% menunjukkan bahwa hampir separuh observasi data uji masih salah diklasifikasikan.

3.2 Evaluasi Tiap Kelas

Kelas	Precision	Recall	F1-score	Support
High	0,65	0,44	0,53	2.497
Low	0,51	0,50	0,51	3.274
Medium	0,48	0,57	0,52	4.229

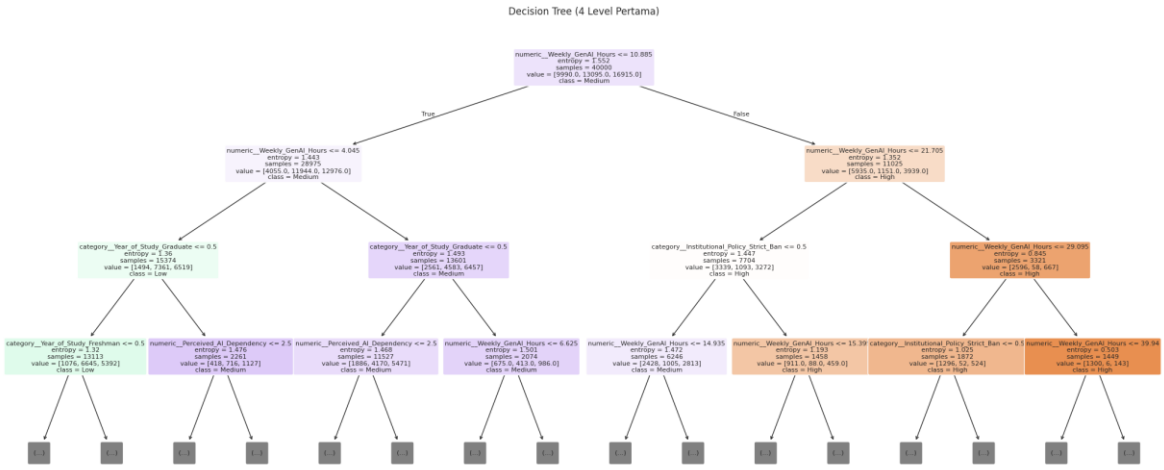


Gambar 3. Confusion Matrix aktual pada 10.000 data uji.

Pada 2.497 data uji dengan label High, model mengklasifikasikan 1.110 secara benar, tetapi 264 dinilai Low dan 1.123 dinilai Medium. Dengan demikian, sebanyak 1.387 kasus High (55,55%) tidak terdeteksi sebagai High. Kesalahan ini perlu menjadi perhatian jika model kelak dikembangkan untuk screening, sebab kasus dengan risiko tinggi berpotensi masuk ke kelompok yang lebih rendah.

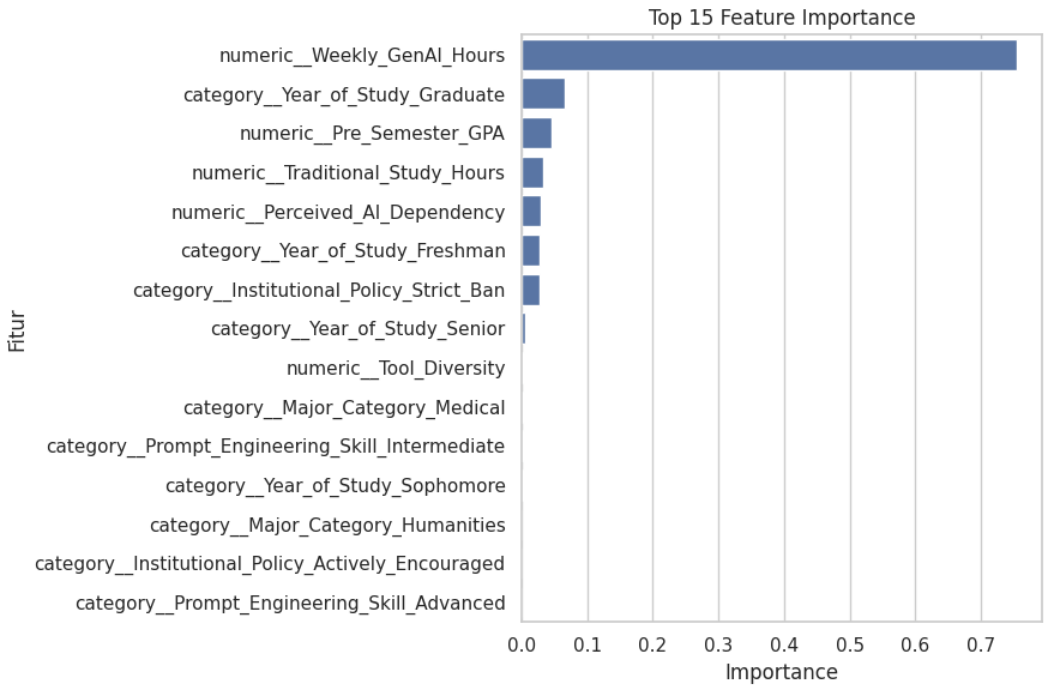
3.3 Interpretasi Struktur Pohon

Notebook memvisualisasikan empat level pertama dari pohon keputusan hasil tuning. Gambar tersebut memperlihatkan sebagian aturan pemisahan, bukan keseluruhan struktur kedalaman maksimum delapan level.



Gambar 4. Empat level pertama dari Decision Tree terlatih.

3.4 Feature Importance



Gambar 5. Peringkat feature importance dari Decision Tree terlatih.

Fitur Weekly_GenAI_Hours menyumbang importance sebesar 0,754946 (sekitar 75,49% dari total impurity-based importance model). Fitur lain yang muncul antara lain Year_of_Study_Graduate (6,54%), Pre_Semester_GPA (4,53%), Traditional_Study_Hours (3,24%), dan Perceived_AI_Dependency (2,88%). Persentase importance adalah kontribusi relatif terhadap penurunan impurity pada pohon, bukan persentase pengaruh kausal terhadap burnout maupun besarnya peningkatan akurasi.

3.5 Prediksi Data Uji dan Keterbatasan

Notebook menghasilkan tabel prediksi untuk observasi X_test yang menyandingkan label aktual, prediksi, dan probabilitas masing-masing kelas (Prob_High, Prob_Low, Prob_Medium). Ini merupakan demonstrasi inferensi pada data uji, bukan prediksi mahasiswa baru di luar dataset. Probabilitas yang ditampilkan belum melalui evaluasi kalibrasi.

Keterbatasan utama meliputi performa prediksi yang masih sedang, recall kelas High yang rendah, belum adanya validasi eksternal atau kalibrasi probabilitas, dan ketidakpastian representativitas dataset untuk populasi mahasiswa nyata. Evaluasi ini hanya berdasarkan satu pembagian uji terstratifikasi dan cross-validation pada data latih. Model tidak boleh digunakan untuk diagnosis maupun keputusan individual tanpa evaluasi dan pengawasan tambahan.

BAB IV. PENUTUP

4.1 Kesimpulan

Algoritma Decision Tree dapat diimplementasikan untuk mengklasifikasikan tingkat risiko burnout mahasiswa menjadi Low, Medium, dan High pada dataset AI Impact on Students. Hasil pengujian menunjukkan accuracy 51,72%, balanced accuracy 50,63%, dan F1-macro 0,5183, yang lebih baik daripada baseline. Namun, recall High sekitar 44% mengindikasikan bahwa model masih

melewatkan cukup banyak kasus berlabel risiko tinggi. Weekly_GenAI_Hours merupakan fitur yang paling dominan dalam struktur pohon, tetapi temuan tersebut bersifat prediktif dan tidak cukup untuk menyimpulkan pengaruh sebab-akibat.

4.2 Saran Pengembangan

- Menguji class_weight, cost-sensitive learning, dan metrik recall High untuk mengurangi kasus risiko tinggi yang terlewat.
- Membandingkan algoritma lain, seperti Random Forest atau Gradient Boosting, dengan prosedur evaluasi yang setara.
- Melakukan validasi eksternal serta memeriksa asal, definisi, dan reliabilitas label burnout sebelum implementasi nyata.
- Menganalisis kualitas probabilitas prediksi, fairness, dan dampak kesalahan klasifikasi sebelum pengambilan keputusan.

SUMBER DATA DAN IMPLEMENTASI

Dataset Kaggle: https://www.kaggle.com/datasets/laveshjadon/ai-impact-on-students

Notebook Google Colab:
https://colab.research.google.com/drive/1W_MgOe393FRvkZgZB9UzKVAhPXcmIZK9

Sumber angka dan grafik: output notebook Google Colab yang dijalankan pada 13 Oktober 2026. Seluruh hasil evaluasi dalam laporan mengikuti output yang tersedia saat dokumen disusun.